



---

# RÉSOLUTION DE PROBLÈMES, GÉNÉRATION DE MOTS-CROISÉS

ANDROÏDE M1 – RP

---

Thibault GIGANT  
Laura GREIGE

*Enseignants :*

Patrice PERNY  
Morgan CHOPIN

2015 – 2016

# Table des matières

<b>Introduction</b>	<b>1</b>
<b>1 Modélisation par un CSP et résolution</b>	<b>1</b>
1.1 Modélisation . . . . .	1
1.2 Implémentation . . . . .	1
1.2.1 Les domaines des variables . . . . .	2
1.2.2 Algorithme d'arc consistance <i>AC3</i> . . . . .	3
1.2.3 Heuristiques . . . . .	4
1.2.4 Algorithme du Retour Arrière Chronologique avec Forward Checking . . . . .	5
1.2.5 Conflict BackJumping . . . . .	5
1.3 Expérimentation . . . . .	5
<b>2 Extension au cas pondéré</b>	<b>7</b>
2.1 Modélisation . . . . .	7
2.2 Expérimentation . . . . .	8
2.3 Expérimentation . . . . .	9
2.4 Bonus . . . . .	9
<b>Conclusion</b>	<b>10</b>

## Introduction

Dans ce projet, on s'intéresse à compléter une grille de taille  $M \times N$ . Dans un premier temps, on modélisera ce problème comme un problème de satisfaction de contraintes et on développera plusieurs méthodes différentes de recherche d'une solution au problème CSP : arc consistance du graphes des contraintes (*AC3*), retour arrière chronologique (*RAC*) avec forward checking (*FC*), et conflict back-jumping (*CBJ*) avec *FC* lui aussi aussi. La grille peut être déjà partiellement remplie par l'utilisateur.

Dans un second temps, on modélisera ce problème comme un CSP valué. Chaque mot du dictionnaire sera muni d'un poids positif ou nul appartenant à  $[0, 1]$  et on développera un algorithme de type Branch and Bound qui permette de rechercher la solution optimale qui serait la solution de poids maximal dans la grille.

## 1 Modélisation par un CSP et résolution

### 1.1 Modélisation

Pour résoudre ce problème, on peut le modéliser comme un problème de satisfaction de contraintes en associant une variable à chaque mot de la grille. Supposons qu'il y ait  $m$  mots dans la grille.

**Variables :**  $x_i$ ,  $\forall i \in \{1, \dots, m\}$

**Domaines :** Soit *dict* un dictionnaire de mots admissibles :

$$D(x_i) = \text{dict}$$

**Contraintes :**

— Soit  $l_i$  la taille du mot en  $i$  et *len* une fonction renvoyant le nombre de lettres d'une variable :

$$\text{len}(x_i) = l_i \tag{1}$$

— Pour tous mots  $x_i$  et  $x_j$  qui se croisent à la  $q$ -ième lettre de  $x_i$  et à la  $p$ -ième lettre de  $x_j$ , on a :

$$x_i[q] = x_j[p] \tag{2}$$

— Si l'on ajoute la contrainte supplémentaire qu'un même mot ne peut apparaître plus d'une fois dans la grille, il suffit d'ajouter la contrainte *AllDiff* :

$$\text{AllDiff}(x_1, x_2, \dots, x_m) \tag{3}$$

### 1.2 Implémentation

Tout cela doit être implémentée de la manière la plus simple possible en machine. Voici ce qui a été effectué pour ce projet

### 1.2.1 Les domaines des variables

Pour récupérer les domaines des variables, une fonction qui lit un fichier contenant une liste de mots a été créé. Cette fonction lit chaque mot du fichier et le stocke dans un dictionnaire Python dont les clés sont la taille des mots contenus. En revanche, les mots ne sont pas stockés sous la forme d'une simple liste. En effet, chaque domaine de mots d'une certaine longueur est représenté par une structure arborescente contenant tous les mots de cette taille. Chaque noeud contient un caractère. Ainsi, un chemin entre la racine et une feuille représente un mot. Les feuilles sont signifiées par une chaîne vide, signalant une fin de mot. La figure suivante montre un arbre contenant quatre mots de longueur 3 :




FIGURE 1 – Représentation arborescente d'un domaine

De cette manière, il est alors beaucoup plus rapide d'effectuer des tests de consistance. Effectivement, si on souhaite par exemple fixer la première lettre au caractère « c » il ne suffit alors plus que de retirer tous les noeuds descendant de la racine dont la donnée n'est pas un « c ». En une itération, avec l'exemple précédent, on retirerait alors 3 mots en une seule itération. On peut alors faire de même si l'on veut fixer la deuxième lettre. Il suffit, pour chaque noeud sous la racine, de retirer ses fils qui n'ont pas la lettre voulue. Et ainsi de suite...

Dans le pire des cas, on veut fixer la dernière lettre, et on devra parcourir tout l'arbre. En pratique, il est certain que le temps gagné en retirant les branches situées en haut de l'arbre compense largement ce problème.

Il faut aussi noter que pour des dictionnaires de petite taille, la probabilité d'avoir des mots assez

similaires, et donc un arbre plus restreint, est assez faible. Cependant, sur les petits dictionnaires, les algorithmes se résolvent très rapidement, car les domaines des variables sont eux aussi petits. Sur ceux de grande taille, la probabilité d’avoir des mots plutôt similaires est beaucoup plus élevée. Cette représentation accélérera donc grandement l’exécution des algorithmes, qui lorsqu’il s’agira de ne garder que les mots ayant une lettre précise à une position précise, pourront ne garder qu’une branche à tous les niveaux concernés.

Pour chaque variable, on donnera alors comme domaine l’arbre du dictionnaire récupéré correspondant à sa taille. En lui donnant un arbre contenant uniquement les mots de sa taille, on effectue déjà la satisfaction de la contrainte (1) est déjà vérifiée. Il n’y aura plus que les deux autres contraintes à satisfaire.

### 1.2.2 Algorithme d’arc consistance AC3

Grâce à la représentation des domaines explicitée dans la sous-section précédente (1.2.1), cet algorithme est réellement simple à appliquer. L’algorithme du cours a été appliqué, avec une légère modification : lorsqu’on regarde un couple de variables liées par une contrainte binaire, les deux domaines sont modifiés à la même itération. Voici l’algorithme appliqué

---

**Algorithm 1:** Procédure AC3

---

**Entrées:**

Variables  $x_i, \forall i \in 1, \dots, m$

```

1  début
2  |  $file := \text{creerFile}()$ 
3  | pour  $(x_i, x_j), i < j$  liées par une contrainte faire
4  | |  $\text{enfiler}((x_i, x_j))$ 
5  | fin
6  | tant que  $\text{estNonVide}(file)$  faire
7  | |  $(x_i, x_j) := \text{defiler}(file)$ 
8  | |  $\text{change1}, \text{change2} = \text{REVISE}(x_i, x_j)$ 
9  | | si  $\text{change1}$  alors
10 | | | pour  $(x_k, x_i), k < i$  liées par une contrainte faire
11 | | | |  $\text{enfiler}((x_k, x_i))$ 
12 | | | fin
13 | | | pour  $(x_i, x_k), i < k$  liées par une contrainte faire
14 | | | |  $\text{enfiler}((x_i, x_k))$ 
15 | | | fin
16 | | fin
17 | | si  $\text{change2}$  alors
18 | | | pour  $(x_k, x_j), k < j$  liées par une contrainte faire
19 | | | |  $\text{enfiler}((x_k, x_j))$ 
20 | | | fin
21 | | | pour  $(x_j, x_k), j < k$  liées par une contrainte faire
22 | | | |  $\text{enfiler}((x_j, x_k))$ 
23 | | | fin
24 | | fin
25 | fin
26 fin

```

---

Avec la procédure REVISE suivante :

---

**Algorithm 2:** Procédure REVISE

---

**Entrées:**

Variables  $x_i$  et  $x_j$  liées par une contrainte

```

1  début
2  |  $i :=$  indice de la lettre soumise à la contrainte de la variable  $x_i$ 
3  |  $j :=$  indice de la lettre soumise à la contrainte de la variable  $x_j$ 
4  |  $lettres_i :=$  ensemble de lettres en position  $i$  de  $x_i$ 
5  |  $lettres_j :=$  ensemble de lettres en position  $j$  de  $x_j$ 
6  |  $intersection :=$  intersection des ensembles  $lettres_i$  et  $lettres_j$ 
7  |  $modifications := [False, False]$ 
8  | si  $lettre_i \neq intersection$  alors
9  | | Retirer de l'arbre domaine de  $x_i$  toutes les lettres au niveau  $i$  qui ne sont pas dans
   | |  $intersection$   $modifications[0] := True$ 
10 | fin
11 | si  $lettre_j \neq intersection$  alors
12 | | Retirer de l'arbre domaine de  $x_j$  toutes les lettres au niveau  $j$  qui ne sont pas dans
   | |  $intersection$   $modifications[1] := True$ 
13 | fin
14 | retourner  $modifications$ 
15 fin

```

---

En procédant comme cela, on ne calcule pour chaque couple de variable qu'une seule fois les lettres communes et leur intersection, en modifiant les domaines des deux variables. En suivant à la lettre l'algorithme du cours, on aurait été obligé de calculer ces données une fois pour  $(x_i, x_j)$  et une fois pour  $(x_j, x_i)$ . On améliore ainsi de beaucoup la vitesse de calcul.

### 1.2.3 Heuristiques

Plusieurs heuristiques permettant de choisir le prochain mot à instancier ont été testées :

**heuristic\_next** : Cette heuristique renvoie simplement la prochaine parmi celles qui ne sont pas encore instanciées.

**heuristic\_max\_constraints** : Cette heuristique renvoie le mot qui possède le plus de contraintes binaires.

**heuristic\_min\_domain** : Cette heuristique renvoie le mot qui possède le plus petit domaine.

**heuristic\_constraints\_and\_size** : Cette heuristique renvoie le mot qui possède le plus de contraintes binaires, et en cas d'égalité celui d'entre eux qui a le plus petit domaine.

**heuristic\_size\_and\_constraints** : Cette heuristique renvoie le mot qui possède le plus petit domaine, et en cas d'égalité celui d'entre eux qui a le plus de contraintes binaires.

**heuristic\_max\_constraints\_with\_instanciated** : Cette heuristique renvoie le mot qui possède le plus de contraintes binaires avec les mots déjà instanciés, et en cas d'égalité celui d'entre eux qui a le plus petit domaine.

Dans tous les cas (hormis **heuristic\_next** qui n'en a pas besoin), en cas d'égalité à la fin des calculs, une variable correspondant au critère est choisie au hasard. De cette manière, deux lancements sur la même grille avec le même dictionnaire pourront donner des résultats différents.

#### 1.2.4 Algorithme du Retour Arrière Chronologique avec Forward Checking

Pour cet algorithme, le modèle du cours a été encore une fois appliqué avec une légère variation. Après avoir instancié un mot et lancé l'algorithme de Forward Checking, et avant de lancer l'appel récursivement avec les variables qui restent à instancier, on vérifie que lors du Forward Checking on n'a pas vidé complètement le domaine d'une variable qui était liée par une contrainte binaire. Dans ce cas, l'instanciation courante ne pourra pas donner de résultat satisfaisant, et il est inutile de faire l'appel récursif. Il faut alors rétablir les domaines qui ont été modifiés, comme si l'appel récursif avait échoué.

De plus, l'avantage de cette méthode, mise à part l'accélération évidente de la vitesse de calcul d'une solution, est qu'elle permet de diminuer l'avantage que comporte le fait d'utiliser l'heuristique renvoyant la variable avec le plus petit domaine. En effet, sans ce changement, lors d'un Forward Checking vidant complètement le domaine d'une variable liée, l'heuristique des plus petits domaines renverra systématiquement la variable dont le domaine a été vidé, et cet appel récursif échouera, et le retour arrière sera immédiat. Avec une autre heuristique, il est possible qu'un autre mot, au pire avec un domaine immense, soit choisi. On ne saura alors que bien plus tard que c'est à ce niveau là qu'il fallait revenir.

Nous sommes conscient que cet ajout rend moins avantageux l'algorithme de Conflict BackJumping qui ne remarquera ce le conflit qu'une fois arrivé à la variable. Certes, *CBJ* retournerait plus vite à l'itération conflictuelle que le *RAC* sans cet ajout, mais il peut quand même perdre du temps à aller vérifier des variables avec un domaine potentiellement grand, avant d'arriver à celle qui comportait un conflit.

#### 1.2.5 Conflict BackJumping

Cette fois, l'algorithme du cours a été appliqué à la lettre. Notons toutefois que le Forward Checking a lui aussi été appliqué à chaque instanciation de variable. Ceci a rendu la recherche d'un conflit local inutile. En effet, il y a conflit local seulement si une instanciation de cette variable est incompatible avec l'instanciation d'une variable précédente. Cela ne peut arriver, puisqu'on a préalablement vidé le domaine de la variable courante des potentiels conflits par Forward Checking.

Il est d'ailleurs intéressant de noter, comme le montrent les résultats de la section suivante, que le *CBJ* donne une solution moins rapidement que *RAC*. La raison pour cela a été donnée dans le dernier paragraphe de la section précédente (1.2.4).

### 1.3 Expérimentation

#### Application

Dans cette section, nous allons tester les performances de nos algorithmes, d'abord en utilisant *RAC* avec Forward Checking sans AC3 préalable, ensuite *RAC* avec Forward Checking et AC3 préalable.

	Grille A	Grille B	Grille C
AC3	t1	t2	t3
FC sans AC3 préalable	t1	t2	t3
FC avec AC3 préalable	t1	t2	t3

#### Conflict BackJumping

#### Applications sur des grilles de tailles plus grandes

La méthode ( ) étant la plus efficace, on l'applique sur des instances de grilles de tailles plus grandes.

	Temps d'exécution	% de solution trouvée
Taille = 10	t1	%
Taille = 100	t2	%



## 2 Extension au cas pondéré

### 2.1 Modélisation

Dans cette partie, on suppose que chaque mot du dictionnaire est muni d'un poids réel positif ou nul appartenant à  $[0, 1]$  représentant l'importance qu'un utilisateur attache à ce mot. Pour trouver la solution optimale du problème, c-à-d la solution de poids maximum dans la grille, il faut utiliser une méthode exacte, comme le « Branch & Bound » qui sera représenté par un arbre de recherche binaire.

Chaque sous-problème créé au cours de l'exploration est désigné par un nœud qui représente les mots choisis pour chaque variable  $x_i$  de la grille. Les branches de l'arbre symbolisent le processus de séparation, elles représentent la relation entre les nœuds (ajout du mot  $m_i \in D(x_i)$ ). Cette méthode arborescente nous permettra donc d'énumérer toutes les solutions possibles.

En chacune des feuilles de l'arbre, on a une solution possible qui correspond ou non à une solution admissible et on retient la meilleure solution obtenue, qui dans ce cas, sera la solution étant poids maximum.

Pour améliorer la complexité du « Branch & Bound », seules les solutions qui vérifient les contraintes de consistances potentiellement de bonne qualité seront énumérées, les solutions ne pouvant pas conduire à améliorer la solution courante ne sont pas explorées.

Le « Branch & Bound » est basé sur trois principes :

#### Principe de séparation

Le principe de séparation consiste à diviser le problème en un certain nombre de sous-problèmes qui ont chacun leur ensemble de solutions réalisables. En résolvant tous les sous-problèmes et en prenant la meilleure solution trouvée, on est assuré d'avoir résolu le problème initial. Ce principe de séparation est appliqué de manière récursive à chacun des sous-ensembles tant que celui-ci contient plusieurs solutions. Remarque : La procédure de séparation d'un ensemble s'arrête lorsqu'une des conditions suivantes est vérifiée :

- on sait que l'ensemble ne contient aucune solution admissible (cas où les mots ne vérifient pas les conditions de consistance) ;
- on connaît une solution meilleure que toutes celles de l'ensemble ;

#### Principe d'évaluation

Le principe d'évaluation a pour objectif de connaître la qualité des nœuds à traiter. La méthode de « Branch and Bound » utilise deux types de bornes : une borne inférieure de la fonction d'utilité du problème initial et une borne supérieure de la fonction d'utilité. La connaissance d'une borne inférieure du problème et d'une borne supérieure de la fonction d'utilité de chaque sous-problème permet d'arrêter l'exploration d'un sous-ensemble de solutions qui ne sont pas candidats à l'optimalité.

- borne supérieure :
- borne inférieure :

#### Parcours de l'arbre

Le type de parcours de l'arbre permet de choisir le prochain nœud à séparer parmi l'ensemble des nœuds de l'arborescence. L'exploration en profondeur privilégie les sous-problèmes obtenus par le plus

grand nombre de séparations appliquées au problème de départ, c'est-à-dire aux sommets les plus éloignés de la racine (= de profondeur la plus élevée). L'obtention rapide d'une solution admissible en est l'avantage.

### 2.2 Expérimentation

## 2.3 Expérimentation

## 2.4 Bonus

La section bonus a été réalisée. Les pages relatives aux UE du site web `androide.lip6.fr` ont été copiées dans un fichier texte. C'est ce texte qui a servi de référence pour la création du dictionnaire. Il y a beaucoup de mots, les fréquences sont donc très petites. Malheureusement, la taille de ce dictionnaire étant très grand, il est difficile de lancer l'algorithme de Branch And Bound qui prend beaucoup trop de temps.

## Conclusion